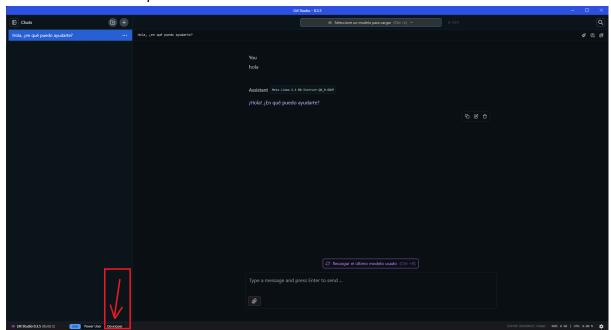
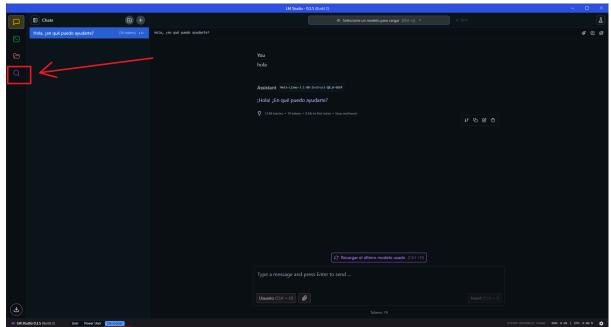

Paso 1: modo "developer":




Paso 2: Buscamos un modelo para descargar.




Paso 3: descargar un modelo



En nuestro caso tenemos nuestras propias versiones:



Paso 4: Levantar el servidor.



Primero: Cargamos el modelo (Ilama 3.1 WIS).

Segundo: Cargamos el modelo de embeding (Nomic Embed Text 1.5)

Tercero: Oprimimos en "Start Server".

Correr el chatbot:

Pre requisitos: Cuda toolkit y PyThorch

Página oficial de Cuda toolkit:

 $\underline{https://developer.nvidia.com/cuda-downloads?target_os=Windows\&target_arch=x86_64\&target_versi$

on=10&target type=exe local

Página oficial de PyThorch: https://pytorch.org/get-started/locally/ **Librerías necesarias (instalar antes de correr los scripts):**

pip install numpy==1.26.4

pip install scikit-learn==1.5.2

pip install requests==2.32.3

pip install tqdm==4.66.5

pip install streamlit==1.38.0

pip install python-docx==1.1.2

pip install pypdf==5.1.0

pip install sentence-transformers==2.7.0

pip install chromadb==0.5.20

pip install llama-index-embeddings-huggingface

pip install llama-index-embeddings-instructor

pip install llama-index

pip install langchain==0.3.12

pip install langchain-community==0.3.12

pip install langchain-core==0.3.25

pip install langchain-huggingface==0.1.2

pip install langchain-chroma==0.1.4

pip install langchain-openai==0.1.14

pip install langchain-text-splitters==0.3.3

pip install langchainhub==0.1.21

También se puede instalar todas las dependencias de una sola vez utilizando el archivo requirements.txt: pip install -r requirements.txt

Crear la base de datos de vectores de RAG:

python create_database.py

Correr el chatbot (Es necesario tener el servidor de LLMStudio levantado):

streamlit run app.py